

2018 年 11.10-12.5 工作总结

陈贝

一、工作进展

1. 认真阅读了文献（Zhang K,Zuo W,et al.Beyond a Gaussian Denoiser:Residual Learning of Deep CNN for Image Denoising[J].IEEE Transactions on Image Processing.2017,26(7):3142），并且总结了此篇文章的大致结构，附录为阅读文章后总结的笔记
2. 简单地学习了深度学习库 Tensorflow，实现 DnCNN 去噪模型还需要对此深度学习库熟练掌握、灵活运用。因为对于大多数人而言，从零开始全部自己实现并不现实，而现在深度学习已经很成熟了，利用一些深度学习框架会更加实用，也会使工作更加高效。另外，如果自己毕业以后要从事这方面的工作，这些经验会帮助自己很多。
3. 花费了几天时间在电脑上安装 Python 专门用于数据科学领域的 IDE（Anaconda）、几个常用的数据科学计算的第三库（numpy、matplotlib 等），在此过程收获了很多，并且在中国大学 MOOC 上学习了北京理工大学的 Python 数据分析与展示课程。

二、工作展望

- 1、阅读 Zhang 论文中提到的多种神经网络去噪方法的论文、以及实现一些经典的去噪方法
- 2、深入学习深度学习框架 Tensorflow，争取实现 Zhang 论文中提出的 DnCNN 去噪方法

附录一

论文笔记：DnCNN: Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising

论文信息：

3142

IEEE TRANSACTIONS ON IMAGE PROCESSING, VOL. 26, NO. 7, JULY 2017

Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising

Kai Zhang, Wangmeng Zuo, *Senior Member, IEEE*, Yunjin Chen, Deyu Meng,
and Lei Zhang, *Senior Member, IEEE*

摘要：

提出网络：DnCNNs

关键技术：Residual learning and batch normalization 残差学习和批归一化

解决问题：Gaussian denoising (nonblind and blind) 高斯去噪（盲和非盲）

Single image super-resolution (SISR) 单幅图像超分辨率

JPEG image deblocking 解压缩

一、原理介绍：

之前的进展：

- (1) 通过建模图像先验建立模型
- (2) 判别式学习

本文使用 CNN 的 3 个原因：

- (1) 架构非常深厚的 CNN 能够有效地提高挖掘图像特征的能力和灵活性
- (2) CNN 训练的正规化和学习方法已经取得了相当大的进步，包括非线性修正单元(ReLU)、批处理归一化和残差学习。这些方法可以应用于 CNN 中，加快训练过程，提高去噪性能。
- (3) CNN 非常适合在现代强大的 GPU 上进行并行计算，可以利用 GPU 提高运行时性能。

本文创新：

- (1) 提出一个端到端的可训练的 CNN 网络，采用残差学习策略，在网络的隐层隐式地移除干净图片 (clean image)。即输入为带噪的观测图片 (noisy image)，输出为移除了干净图片的残差 (噪声) 图片 (residual image)。这样做的动机是，用残差学习刻画恒等映射或近似的恒等映射，效果要比直接学习干净图片要相对好
- (2) 采用残差学习和批归一化加速训练并提升性能
- (3) DnCNN 可以很容易地扩展到处理一般的图像去噪任务，训练单一的 DnCNN 模型，有望仅用一个 DCNN 模型解决图像去噪的三个一般任务

二、相关工作：

A. Deep Neural Networks for Image Denoising (a specific model is trained for a certain noise level)

- (1) 多层感知机 the multilayer perceptron (MLP)
- (2) a trainable nonlinear reaction diffusion (TNRD) model

B. Residual Learning and Batch Normalization

- (1) 残差学习 Residual Learning
- (2) 批归一化 Batch Normalization

三、提出的 CNN 去噪模型

针对某一特定任务训练深度 CNN 模型一般包括两个步骤：

(1) 网络架构设计； (2) 通过训练数据训练模型

A 网络深度

滤波器尺寸 3*3，但去除所有的池化层。故对于 d 层的 DnCNN，感受野为 $(2d+1)(2d+1)$ 。确定感受野的大小：

(1) 其他经典方法的感受野大小：

表 1
噪声水平 $\sigma = 25$ 时不同方法下的有效 patch 尺寸

Methods	BM3D [2]	WNNM [13]	EPLL [33]	MLP [24]	CSF [14]	TNRD [16]
Effective Patch Size	49×49	361×361	36×36	47×47	61×61	61×61

(2) 本文中：

对于特定噪声水平的高斯去噪，我们设置 DnCNN 感受野为 35*35，深度为 17 层

对于其它通用去噪任务，我们利用一个更大的感受野和 20 层的深度

B 网络体系结构




图 1 推荐的 DnCNN 网络的架构

C 图像去噪的剩余学习与批处理归一化的集成




图 2 四种具体模型在两种基于梯度的优化算法下的高斯去噪结果，即 (a) SGD，(b) Adam。四种具体模型分别采用残差学习（RL）和批处理归一化（BN）的不同组合，采用噪声水平 $\sigma = 25$ 进行训练。对来自 Berkeley 分割数据集的 68 幅自然

图像进行了评价。

D 与 TNRD 的联系

略，这部分有点看不懂。

E 扩展到一般性的图像去噪

一般的方法是先估计噪声水平，再用相应噪声水平的模型。这种方法一是效果一般，二是只适用于高斯噪声分布。

由于该论文的方法采用了残差估计，很方便的扩展到了未知水平的高斯去噪，以及常见的三种一般性的去噪任务。

四、实验结果

A 实验设置

DnCNN-S: 用于特定噪声水平的高斯去噪，训练数据为三种噪声水平的共计 128x1600 张 40x40 的补丁。深度为 17。

DnCNN-B: 用于盲高斯去噪，训练数据为噪声水平在 0~55 之间的，尺寸为 50x50 的 128x3000 个补丁。深度为 20。

CDnCNN-B: 用于盲彩色图像去噪，训练数据为噪声水平在 0~55 之间的，尺寸为 50x50 的 128x3000 个补丁。

DnCNN-3: 用于三个一般性图像去噪任务，训练数据为生成的噪声图像，下采样图像，压缩图像。深度为 20。

B 方法比较

C 定量定性评价




图 13 一个显示了我们提出的模型对三个不同任务的处理能力的例子。输入图像由噪声水平 15（左上）和 25（左下）的噪声图像组成，双三次插值上标系数为 2（中上）和 3（中下）的低分辨率图像，质量系数为 10（右上）和 30（右下）的 JPEG 图像组成。

需要注意的是，输入图像中的白线只是用来区分这六个区域，剩余图像归一化到 $[0,1]$ 范围内进行可视化。即使是输入图像在不同的区域受到不同的畸变，恢复后的图像也很自然，没有明显的伪影。（a）输入图像（b）输出残差图像（c）恢复图像。

D 运行时间

E 三种通用图像去噪任务的单模型学习实验

五、结论

本文提出了一种用于图像去噪的深度卷积神经网络，利用残差学习将噪声从噪声观测中分离出来。将批量归一化和剩余学习相结合，加快了训练过程，提高了去噪性能。与传统的针对特定噪声水平训练特定模型的判别模型不同，我们的单一 DnCNN 模型能够处理未知噪声水平的盲高斯去噪。此外，我们还证明了训练单个 DnCNN 模型来处理三种常规图像去噪任务的可行性，这三种任务包括未知噪声水平的高斯去噪、多尺度因子的单图像超分辨率去噪和不同质量因子的 JPEG 图像去块。大量的实验结果表明，该方法不仅在定量和定性上具有良好的图像去噪性能，而且通过 GPU 实现具有良好的运行时间。在未来，我们将研究合适的 CNN 模型用于去除具有真实复杂噪声的图像，以及其他一般的图像恢复任务。